KOLANI Julien Yendoupabe

Master 1 IS – Semestre 2, EPL - Université de Lomé

01 mai 2025

Détection d'anomalies dans les transactions bancaires avec K-means

Objectif

Utiliser K-means pour identifier automatiquement les comportements inhabituels dans un ensemble de transactions synthétiques. Les clusters modélisent différents comportements et les anomalies peuvent être identifiées en observant les points trop éloignés des centres.

Sommaire :

1. Introduction.....3
2. Préparation des données.....3
3. Stratégie de détection.....4
3.1. Choix de l'algorithme de clustering.....4
3.2. Stratégie d'identification des anomalies.....4
4. Analyse des clusters.....5
4.1. Nombre anomalies détectées.....6
4.2. Interprétations.....6
5. Conclusion.....7

1. Introduction

Dans le cadre d'un projet de supervision de transactions bancaires de 20000 enregistrements l'enjeu de ce projet est de scinder les clients en sous catégories puis de détecter les comportements qui sortent du lot tels que les cas de fraudes, les erreurs de saisies, les transactions refuser et d"autres comportements sortant du lot.

Plutôt que d'étiqueter manuellement chaque transaction une approche non supervisée a été adoptée. Ainsi chaque transaction est caractérisée par un point dans l'espace de coordonnées : **(initial_amount, transfer_amount, amount_received, final_amount)**. La finalité de cette procédure étant de faire émerger les groupes avec des caractéristique semblables et trouver les ligne qui ne rentre dans aucune des cases ou qui s'en éloignent.

Objectifs

- Segmenter les transactions en groupes homogènes via K-means.
- Repérer les transactions extrêmes comme anomalies, en s'appuyant sur la distance au centroïde et des scores intra-cluster.

Méthodologie générale adoptée

- **Clustering non supervisé** avec K-means (k=6) pour modéliser les comportements typiques.
- **Visualisation** des clusters en 2dimenstions pour valider la séparation.
- **Détection d'anomalies** par seuils sur la distance euclidienne au centroïde, complétés par un score de percentile intra-cluster.
- **Interprétation** des regroupements et des anomalies pour en déduire des typologies (overdraft, ghost transactions, etc.).

2. Préparation des données

- **Taille** : 20 000 transactions, identifiées par global_id, sender_id, receiver_id et date.
- **Variables retenues** (après sélection) :
    - initial_amount : solde avant transfert
    - transfer_amount : montant transféré
    - amount_received : montant effectivement reçu
    - final_amount : solde après transaction
    -

3. Stratégie de détection

3.1. Choix de l'algorithme de clustering

K-Means a été retenu pour sa simplicité, sa rapidité et son interprétabilité :

- **Avantages** : partition nette, implémentation optimisée.
- **Limites** : sensibilité aux clusters non sphériques, nécessité de fixer k.

3.2. Stratégie d'identification des anomalies

Les métriques retenues sont notamment **la distance au centroïde**, **la la distance au centroïde en pourcentage** et le **z-score modifié**.

Après application de l'algorithme K-Means pour segmenter les données en clusters la première option envisagée était de déterminer la distance de chaque point au centroid et fixer un seuille puis déclarer tous les points au-delà comme des outlier.

Toutefois, cette approche pose certaines limites pour un nuage de point dispersé et du fait qu'elle ne tienne pas compte de la densité c'est à dire que dans cluster on a un ensemble de point légèrement éloigné mais appartement entièrement au cluster. En plus l'algorithme de K-Means est très sensible aux outlier qui peuvent fausser la position du centroid ce qui biaise également la fixation du seuil. Ce seuil également si ce n'est par un expert métier ne peut aussi être définis très explicitement par conséquent cette méthode montre ses limites dès lors que les clusters présentent une forme elliptique ou une densité non homogène., K-Means repose sur l'hypothèse de clusters sphériques et de densité uniforme. Dans le cas d'une distribution elliptique, certains points peuvent se situer légitimement loin du centroïde le long de l'axe principal de l'ellipse sans pour autant constituer des anomalies. L'application d'un seuil de distance fixe conduit alors à deux erreurs : le rejet de points normaux et le non-repérage de véritables outliers localisés dans des zones de forte densité mais présentant un profil atypique.

L'observation des clusters dans des projections 2D et 3D montre que les nuages de points ne sont pas parfaitement sphériques, ce qui complique la définition d'un seuil de distance unique.

Afin d'améliorer la détection des anomalies nous avons aussi explorer la méthode du modified Z-score qui est celle qui a été adoptée. Cette variante du Z-score classique remplace la moyenne par la médiane et l'écart-type par la Median Absolute Deviation (MAD) renforçant ainsi la robustesse statistique vis-à-vis des valeurs extrêmes. Cette méthode convient particulièrement aux distributions non parfaitement normales observées dans notre jeu de données apres test de normalité suivis d'un plot sur le jeu de données.

Les principales caractéristiques de la méthode sont les suivantes :

- Absence d'hypothèse de normalité : le modified Z-score ne requiert pas que les données suivent une loi gaussienne.
- Robustesse aux outliers : l'usage de la médiane et de la MAD limite l'influence des observations extrêmes sur le calcul du score.
- Mise en œuvre simple : le calcul se résume à l'estimation de la médiane, de la MAD et à l'application de la formule du modified Z-score.

Ses limites résident dans le choix du seuil critique (susceptible de générer faux positifs et faux négatifs), la sensibilité aux paramètres de dispersion, l'absence de prise en compte des relations multivariées et l'incapacité à détecter des anomalies dont la nature ne se traduit pas par une valeur extrême univariée.

Des études menées sur des séries temporelles de mesures de RSS (Received Signal Strength) indiquent que le modified Z-score avec estimateur d'échelle hybride pondéré procure la meilleure performance de détection, avec un très faible taux de fausses alertes et de faux négatifs, et qu'il surpasse des techniques telles que DBSCAN, la détection d'outliers par K-Means ou MOD (Mean-Shift-based Outlier Detection) .

Référence

*Abdulmalik S. Yaro, Filip Maly, Pavel Pražák & Karel Malý, "**Outlier Detection Performance of a Modified Z-Score Method in Time-Series RSS Observation With Hybrid Scale Estimators,**" *IEEE Access*, vol. PP, no. 99, pp. 1–1, Jan. 2024, DOI: 10.1109/ACCESS.2024.3356731.*

4. Analyse des clusters

L'algorithme K-Means a permis de segmenter les transactions en **6 clusters** à savoir :

- **Cluster 0** le plus majoritaire :
    - Transactions principalement normales de faibles montants.
    - Présence massive d'anomalies (1 783 sur 1 849) dues à des montants aberrants très élevés ou négatifs.
    - Montants initiaux à plus de 100 000 avec des virements négatifs ou très élevés.

Ce cluster est représentatif d'un comportement standard, mais fortement bruité par des erreurs ou fraudes massives ou de transactions invalides.

- **Clusters 1 à 4** profils spécifiques :
    - Chaque cluster regroupe des transactions normales autour d'un certain niveau de montant.
    - Les anomalies sont rares mais nettes, souvent associées à : des incohérences entre montants envoyés/reçus et solde final, des virements vers des soldes négatifs,ou des montants disproportionnés par rapport aux habitudes du cluster.
- **Cluster 5** transactions répétitives et suspectes :
    - Très petites transactions avec des motifs très similaires, envoyées par le même utilisateur **sender_id** = 621 vers la même personne.
    - Les anomalies détectées aux extrêmes indiquent un changement brutal de comportement.

Ceci iindique une possible automatisation de virements (bot ou script), voire transactions fantômes récurrentes ou des transactions à détection non voulu a intervalle régulier.

4.1. Nombre anomalies détectées

- **Nombre total d'anomalies détectées** : **1 849** sur l'ensemble des données.
- **Répartition par cluster** :
    - Cluster 0 : 1 783 anomalies
    - Clusters 1 à 5 : entre 11 et 15 anomalies chacun

4.2. Interprétations

- **Cluster 0** concentre des cas extrêmes : virements de montants négatifs, incohérences de solde, ou écarts importants par rapport au centre de gravité du cluster.
- Dans les autres clusters, les anomalies sont plus discrètes mais potentiellement critiques (exple. : soldes finaux négatifs alors que les montants semblent normaux).

- Plusieurs cas suggèrent des **transactions frauduleuses ou mal formées**, comme : des transferts vers des comptes inexistants, des soldes devenant négatifs après un virement, ou des montants incohérents entre les champs **(transfer_amount ≠ amount_received)**.

5. Conclusion

- **Insights** :
  - Une **grande majorité des anomalies sont concentrées dans un seul cluster (0)**, qui mélange des comportements normaux et des cas extrêmes.
  - D'autres clusters plus homogènes permettent d'identifier des profils types de transactions.
  - Le cluster 5 indique potentiellement un **automatisme** ou un **modèle de transaction anormalement répétitif**.
- **Recommandations** :
  - **Renforcer les contrôles** sur les transactions à montant élevé ou négatif.
  - **Effectuer un audit** sur la catégorie de client dans l**e Cluster 0**
  - **Surveiller les comportements répétitifs** ou trop réguliers, en particulier les utilisateurs ayant un historique suspect.
  - **Isoler les transactions anormales du cluster 0** pour un audit manuel ou un traitement spécifique.